Kelompok 6

Early Warning System: Prediksi Risiko Dropout Mahasiswa Menggunakan Machine Learning untuk Deteksi Dini dan Intervensi Akademik

K H A N S A
A T H A Y A

Weekly Report 1

PROJECT BACKGROUND

PROJECT BACKGROUND

Pada tahun 2023 terdapat sekitar 352.494 mahasiswa yang mengalami dropout berdasarkan data Direktorat Jenderal Pendidikan Tinggi.

Kasus dropout dapat disebabkan oleh berbagai faktor seperti:

- Tekanan akademik
- Masalah finansial
- Kurangnya dukungan sosial
- Kesulitan adaptasi akademik

PROBLEM STATEMENT

Apakah kita dapat memprediksi status akademik mahasiswa menggunakan data akademik dan demografi?

Dropout? Enrolled? Graduate?

DATASET

Sumber

https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Fitur

Dataset Student Dropout memiliki 36 fitur dan 1 target. Fitur-fitur tersebut meliputi latar belakang demografi, kondisi sosial-ekonomi keluarga, serta performa akademik mahasiswa pada semester pertama dan kedua. Seluruh data tersebut digunakan untuk memprediksi apakah seorang mahasiswa akan lulus (Graduate), masih aktif (Enrolled), atau putus kuliah (Dropout)

CAKUPAN

Dataset ini dikumpulkan dari sebuah institusi pendidikan tinggi negeri bernama Instituto Politécnico de Portalegre (IPP) di Portugal.

PERAN

Dataset ini dibuat dalam sebuah proyek yang bertujuan untuk berkontribusi dalam mengurangi angka putus kuliah dan kegagalan akademik di pendidikan tinggi, dengan menggunakan teknik machine learning untuk mengidentifikasi mahasiswa yang berisiko sejak tahap awal masa studi mereka, sehingga strategi dukungan bagi mereka dapat segera diterapkan

FITUR-FITUR

A. Demografi
Informasi dasar mengenai identitas pribadi mahasiswa.

1. Marital status
2. Nacionality
3. Displaced (Perpindahan domisili)
4. Gender
5. Age at enrollment
6. International

B. Faktor Sosial-Ekonomi
Informasi mengenai latar belakang keluarga, pekerjaan, dan kondisi finansial.

7. Mother's qualification
8. Father's qualification
9. Mother's occupation
10. Father's occupation
11. Educational special needs
12. Debtor (Memiliki hutang)
13. Tuition fees up to date (Status pembayaran SPP)
14. Scholarship holder (Penerima beasiswa)
15. Unemployment rate (Tingkat pengangguran negara)
16. Inflation rate (Tingkat inflasi negara)
17. GDP (Pertumbuhan ekonomi negara)

FITUR-FITUR

C. Jalur Akademik
Data riwayat pendidikan dan detail pendaftaran sebelum memulai perkuliahan.
18. Application mode
19. Application order
20. Course (Jurusan yang dipilih)
21. Daytime/evening attendance
22. Previous qualification
23. Previous qualification (grade)
24. Admission grade

D. Performa Akademik
Data hasil belajar selama dua semester pertama (Semester 1 & 2).
Semester 1:
25. Curricular units 1st sem (credited)
26. Curricular units 1st sem (enrolled)
27. Curricular units 1st sem (evaluations)
28. Curricular units 1st sem (approved)
29. Curricular units 1st sem (grade)
30. Curricular units 1st sem (without evaluations)
Semester 2:
31. Curricular units 2nd sem (credited)
32. Curricular units 2nd sem (enrolled)
33. Curricular units 2nd sem (evaluations)
34. Curricular units 2nd sem (approved)
35. Curricular units 2nd sem (grade)
36. Curricular units 2nd sem (without evaluations)

TIPE ANALISIS

Prediktif

Untuk memprediksi status akhir mahasiswa (Dropout/Enrolled/Graduate)

Klasifikasi

Karena target variabel berbentuk kategori dengan 3 kelas yang sudah terdefinisi

Pendekatan: Bottom-Down Approach

BUSINESS OBJECTIVE

Deteksi Dini Mahasiswa Berisiko
Identifikasi mahasiswa yang berpotensi dropout

Analisis Faktor Kunci
Temukan variabel yang paling berpengaruh terhadap keberhasilan akademik

Klasifikasi 3 Status Akademik
Prediksi status akhir mahasiswa: Dropout, Enrolled, atau Graduate

Rekomendasi Intervensi
Buat panduan berbasis data untuk program pendampingan mahasiswa

FRAMEWORK - SMART

S — Specific
Membangun model klasifikasi multi-kelas (Dropout/Enrolled/Graduate) menggunakan Decision Tree, Random Forest, dan XGBoost pada dataset 4.424 mahasiswa dengan 36 fitur dari UCI ML Repository.

M — Measurable
Target terukur: Accuracy ≥ 80%, Weighted F1-Score ≥ 0.83, ROC-AUC ≥ 0.90

FRAMEWORK - SMART

A — Achievable
Dataset sudah bersih (no missing values), ukuran memadai untuk ML klasik, algoritma yang dipilih terbukti efektif untuk klasifikasi data tabular.

R — Relevant
Langsung relevan dengan masalah nyata: 352.494 mahasiswa DO di Indonesia (2023), dan kebutuhan institusi pendidikan untuk program intervensi berbasis data.

T — Time-bound
Selesai dalam 3 Weekly Report + Final Pitching sesuai timeline BCC DS 2026.

DISTRIBUSI TARGET DATASET

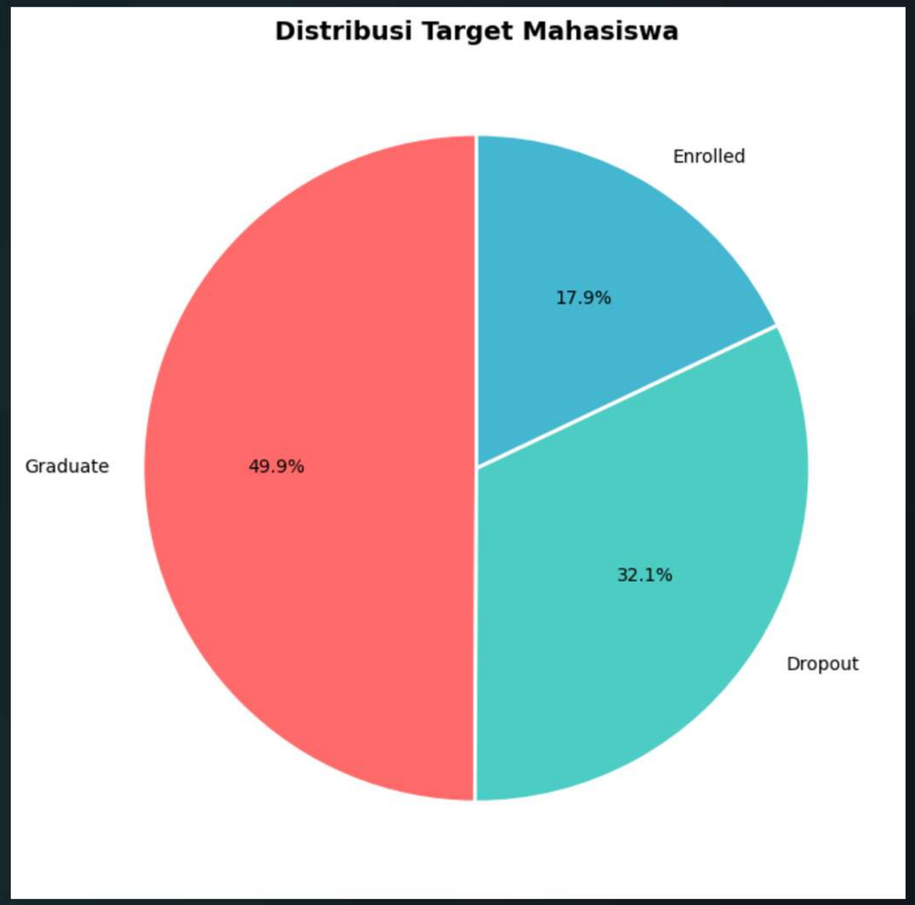

Angka 32.12% menunjukkan hampir sepertiga dari 4424 mahasiswa (1421 orang) tidak menyelesaikan studinya. Bahkan jumlah dropout lebih besar dibandingkan mahasiswa yang masih aktif enrolled (17.95%), artinya lebih banyak mahasiswa yang berhenti kuliah dibandingkan yang melanjutkan kuliah.

Correlation Matrix

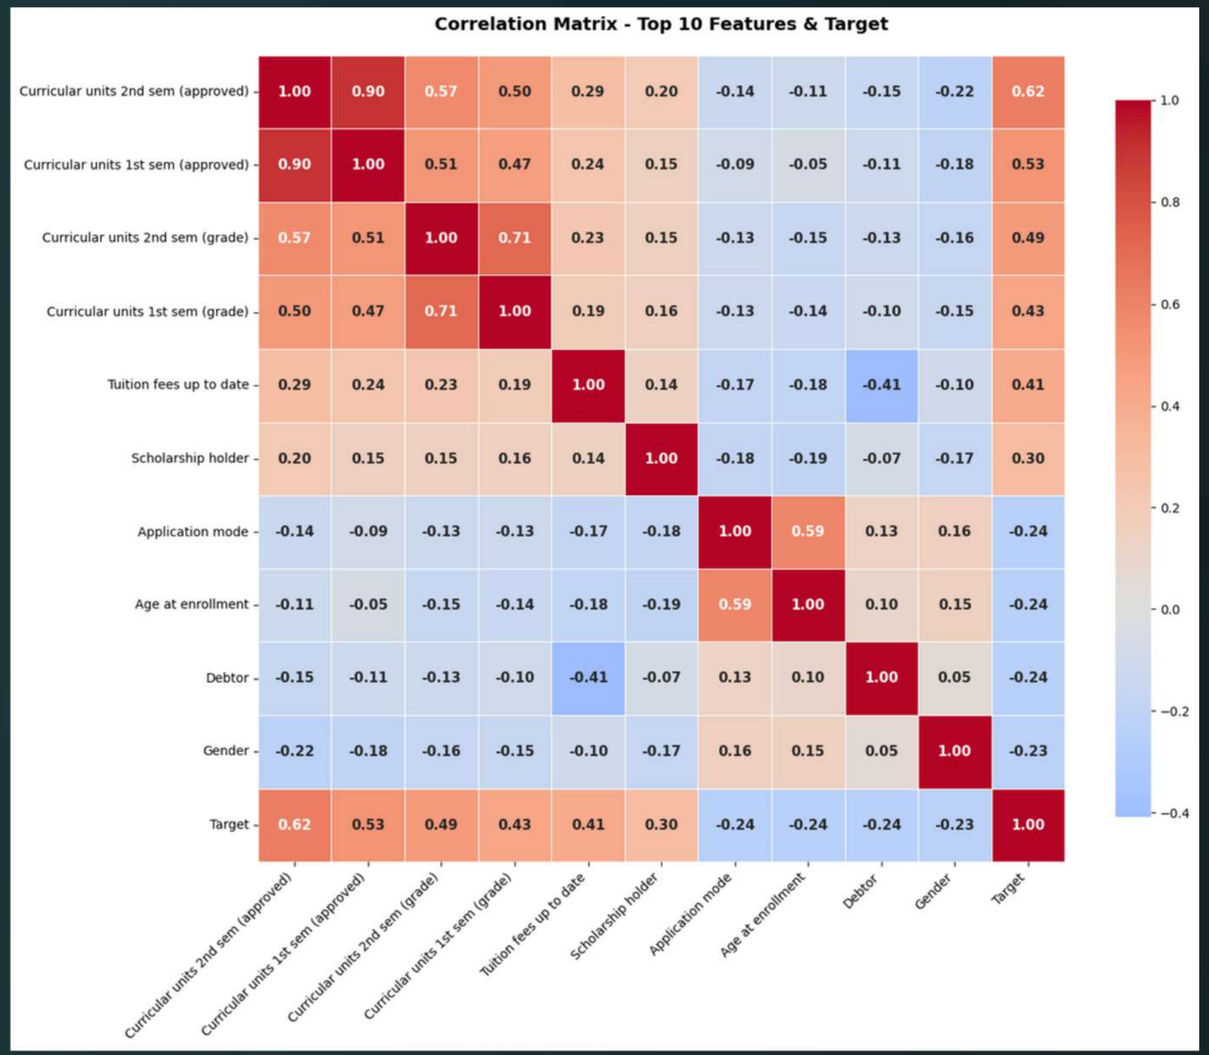

Correlation matrix menunjukkan hubungan linear antar variabel. Fitur curricular units 2nd sem approved memiliki korelasi positif tertinggi (0.62), mengindikasikan mahasiswa yang banyak lulus mata kuliah cenderung Graduated. Sebaliknya, debtor dan age at enrollment berkorelasi negatif (-0.24), mengindikasikan mahasiswa dengan utang atau usia masuk lebih tua cenderung dropout. Selain itu, ditemukan multikolinearitas tinggi antar fitur akademik semester 1 dan 2 (0.90), mengindikasikan adanya redundansi informasi

2 VARIABEL PALING BERKORELASI POSITIF DENGAN TARGET

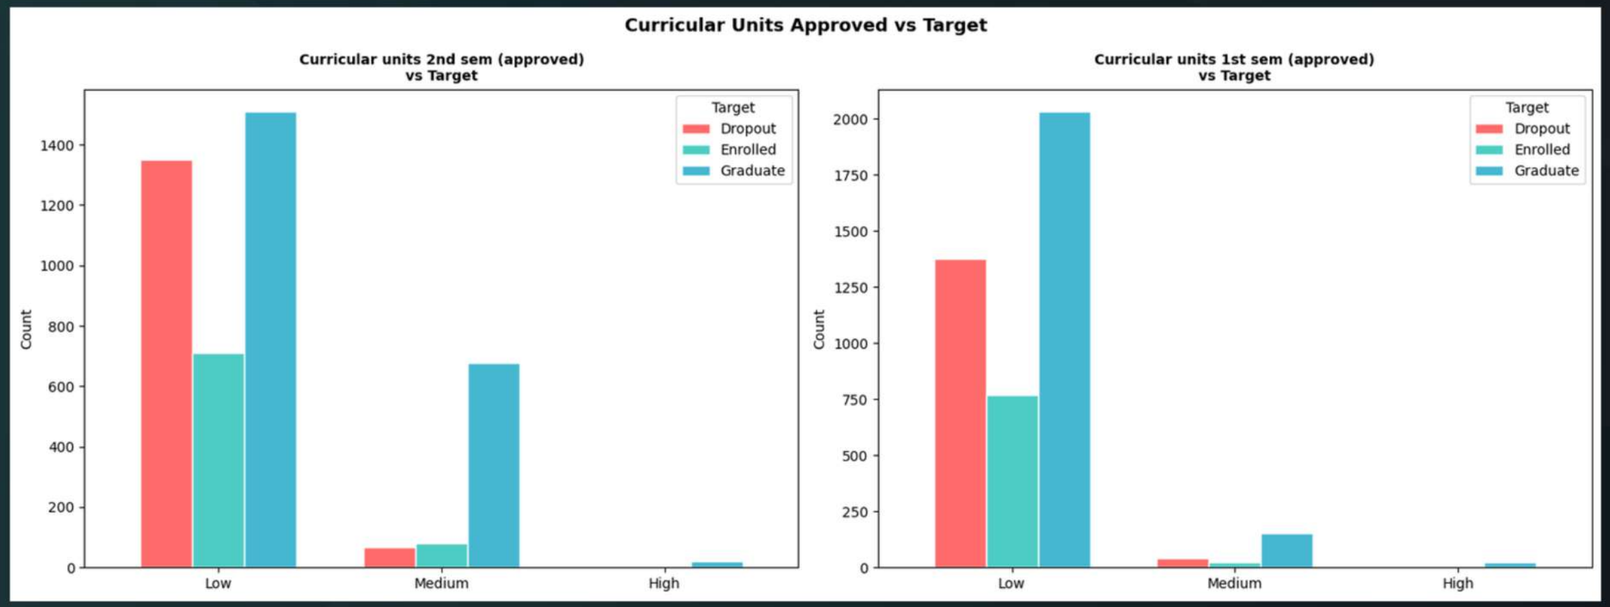

Mahasiswa yang lulus sedikit mata kuliah (Low) di semester 1 maupun semester 2 memiliki jumlah dropout yang tinggi. Sebaliknya, semakin banyak mata kuliah yang lulus (Medium-High), semakin besar kemungkinan mahasiswa tersebut Graduate dan semakin kecil kemungkinan Dropout.

FAKTOR KORELASI POSITIF DENGAN TARGET LAINNYA

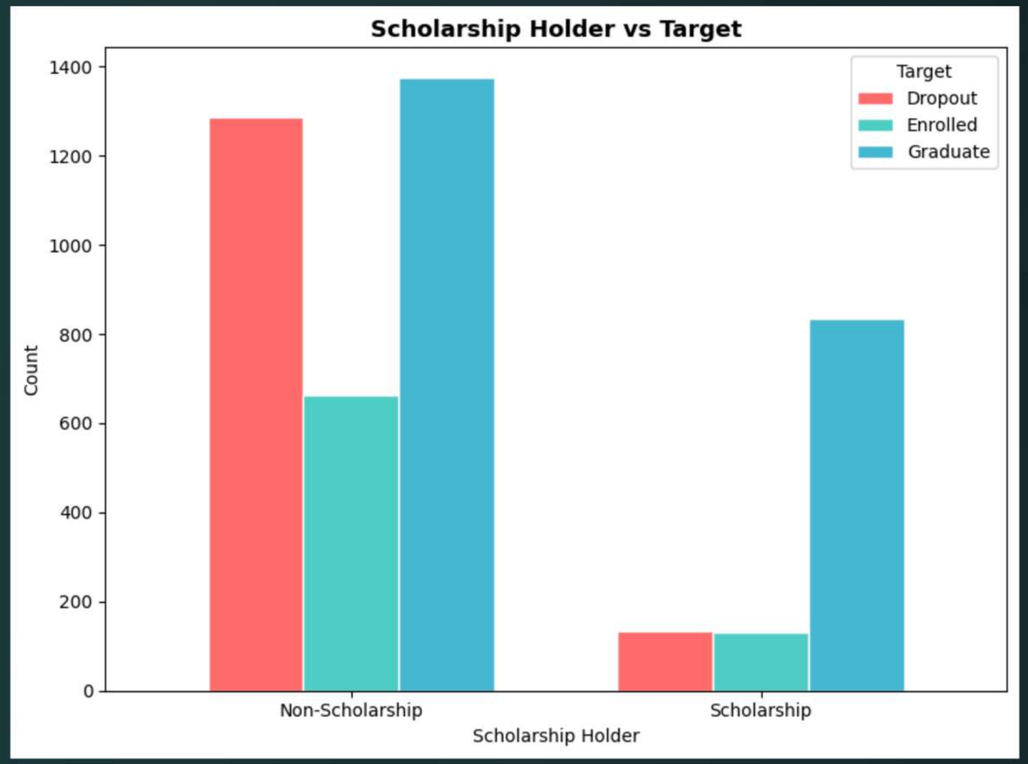

Berdasarkan dataset, mahasiswa penerima beasiswa lebih banyak lulus (75.98%) dibandingkan yang tidak memiliki beasiswa hanya (41.32%). Sebaliknya, mahasiswa non-beasiswa punya risiko dropout 3x lebih tinggi (38.71%) dibandingkan mahasiswa non-beasiswa (12.19%). Ini menunjukkan beasiswa tidak hanya membantu finansial, tetapi juga menjadi motivasi untuk menyelesaikan perkuliahan.

FAKTOR KORELASI NEGATIF TERHADAP TARGET

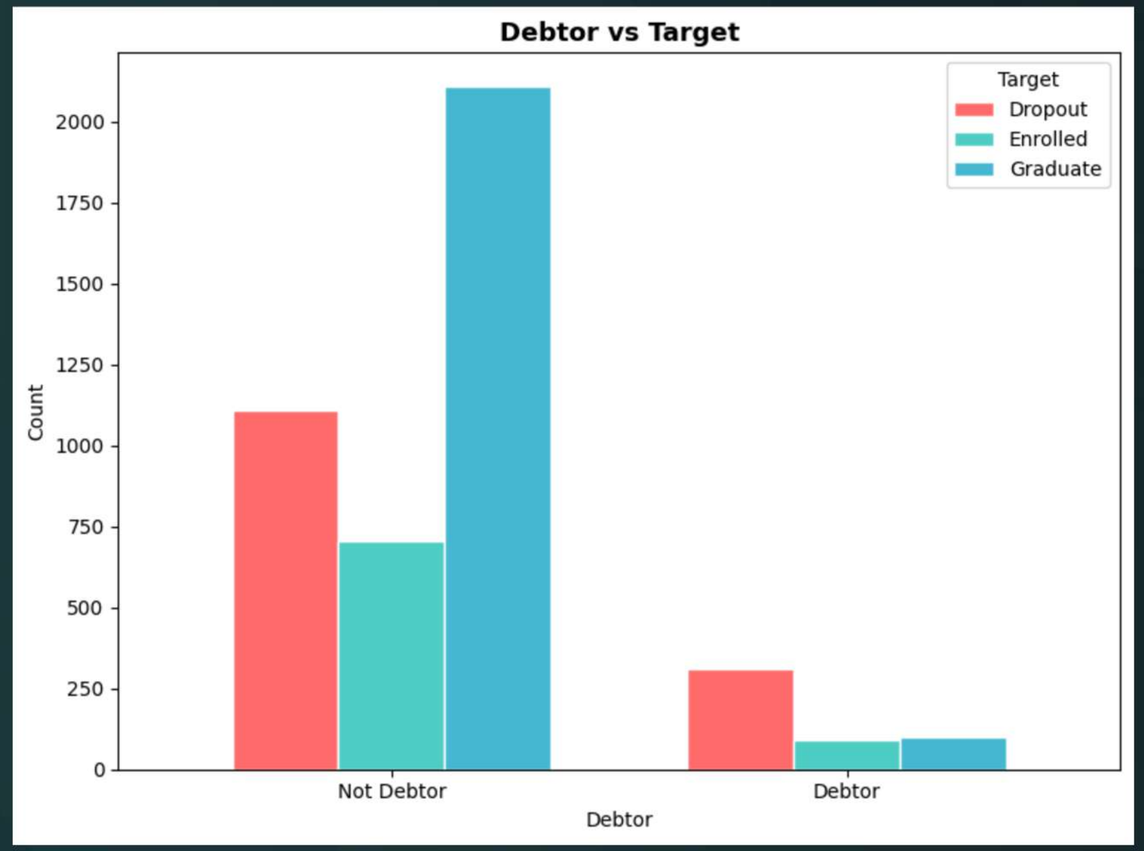

Mahasiswa yang memiliki utang cenderung dropout lebih tinggi (62.03%) dibandingkan yang tidak memiliki utang (28.28%). Sebaliknya, mahasiswa yang tidak memiliki utang memiliki tingkat kelulusan lebih tinggi (53.76%) dibandingkan mahasiswa yang memiliki utang (20.08%).

METRIC EVALUATION

Accuracy

performa model secara keseluruhan

F1-Score per kelas

khususnya kelas Dropout (paling kritis secara bisnis)

Weighted F1-Score

Mengakomodasi class imbalance

ROC-AUC (macro)

kemampuan diskriminasi antar 3 kelas

SHAP Values

explainability individual prediction (Final Pitching)

REFERENCES

Realinho et al., 2022
Predicting Student Dropout and Academic Success
Data Journal (MDPI)
https://doi.org/10.3390/data7110146

Villar & de Andrade, 2024
Supervised Machine Learning Algorithms for Predicting Student Dropout and Academic Success
Discover Artificial Intelligence — Springer Nature
https://doi.org/10.1007/s44163-023-00079-z

Martins et al., 2021
Early Prediction of Student's Performance in Higher Education: A Case Study
WorldCIST Conference — Springer
https://doi.org/10.1007/978-3-030-72657-7_16

Krüger et al., 2023
An Explainable Machine Learning Approach for Student Dropout Prediction
Expert Systems with Applications — Elsevier
https://doi.org/10.1016/j.eswa.2023.120933

THANK YOU